Ringkasan Notebook Pemodelan NUSA-MIPA

DIMAS-TI 2026, Divisi Penambangan Data · Capaian numerasi 514 kabupaten/kota (data Rapor Pendidikan 2025, cross-sectional) · Notebook: NUSA_MIPA_Pemodelan_Numerasi_2025.ipynb

Ringkasan Singkat

Notebook menjalankan empat tahap pipeline sesuai blueprint tim di atas master dataset final (514 kab/kota × 4 jenjang = 2.056 baris, 20 fitur dalam 4 kelompok IPO, target *numerasi_score*). Seluruh sel sudah dijalankan dari awal sampai akhir tanpa error, dan hasilnya disimpan sebagai tabel (folder outputs) dan gambar (folder figures) yang siap dipakai untuk web dan makalah.

Tahap	Hasil utama
2. Clustering	3 klaster tipologi (K-Means, k = 3): 184 / 283 / 47 kab/kota. Silhouette 0,385, Davies-Bouldin 0,896.
2. Transisi jenjang	Median numerasi naik +7,0 dari SD ke SMP, lalu turun −5,0 ke SMA. 62 kab/kota anomali skor, 22 anomali label.
3. OLS vs MGWR	MGWR lebih baik di semua jenjang. Adj R^2 SMP 0,77 (OLS 0,71), SMA 0,75 (0,67), SD 0,72 (0,66), SMK 0,55 (0,43).
3. LightGBM + SHAP	R^2 uji 0,70 pada leave-one-province-out (OLS 0,66). Tanpa literasi turun ke 0,52 (OLS 0,40).
4. Simulasi	Skenario blueprint menaikkan numerasi rata-rata 0,28 poin. Efek per tuas kecil dan sebagian berarah negatif.

Tiga catatan yang perlu diketahui tim. (1) Skor numerasi dan literasi dibentuk dengan cara yang sama sehingga berkorelasi 0,64–0,82; literasi menyumbang pengaruh sekitar 6 kali fitur terkuat berikutnya, jadi R^2 0,70 sebagian besar berasal dari literasi. Hasil tanpa literasi (0,52) lebih jujur untuk menilai fitur kebijakan dan sebaiknya ikut dilaporkan. (2) Target *numerasi_score* adalah estimasi kalibrasi dari SKM provinsi dan label Rapor, bukan skor hasil ukur. (3) Keunggulan MGWR dihitung in-sample, belum diuji pada data yang tidak dilihat model.

1. Persiapan Data

- Sumber: master dataset final tim. 55 kab/kota yang koordinatnya salah letak sudah dikoreksi; nilai lain tidak diubah.
- Fitur dikelompokkan menurut kerangka IPO blueprint: X1 SDM Guru (3), X2 Sarpras dan TIK (7), X3 Iklim dan Pedagogik (7), X4 Kerentanan dan Efisiensi (3).
- *gap_numerasi_literasi* tidak dipakai sebagai fitur karena dihitung langsung dari target (kebocoran). Hanya sebagai indikator diagnostik.
- Tidak ada sel kosong pada fitur dan target. Penanda imputasi (10 baris label "Tidak Tersedia", 13 baris skor hasil imputasi) tersimpan sebagai kolom flag.
- Autokorelasi spasial (Moran's I) numerasi signifikan di keempat jenjang: SD 0,61, SMP 0,56, SMA 0,63 (kuat), SMK 0,04 (sangat lemah). Ini dasar statistik untuk memakai model spasial lokal, dengan catatan SMK paling lemah.

2. Clustering Profil 6 Dimensi IPO

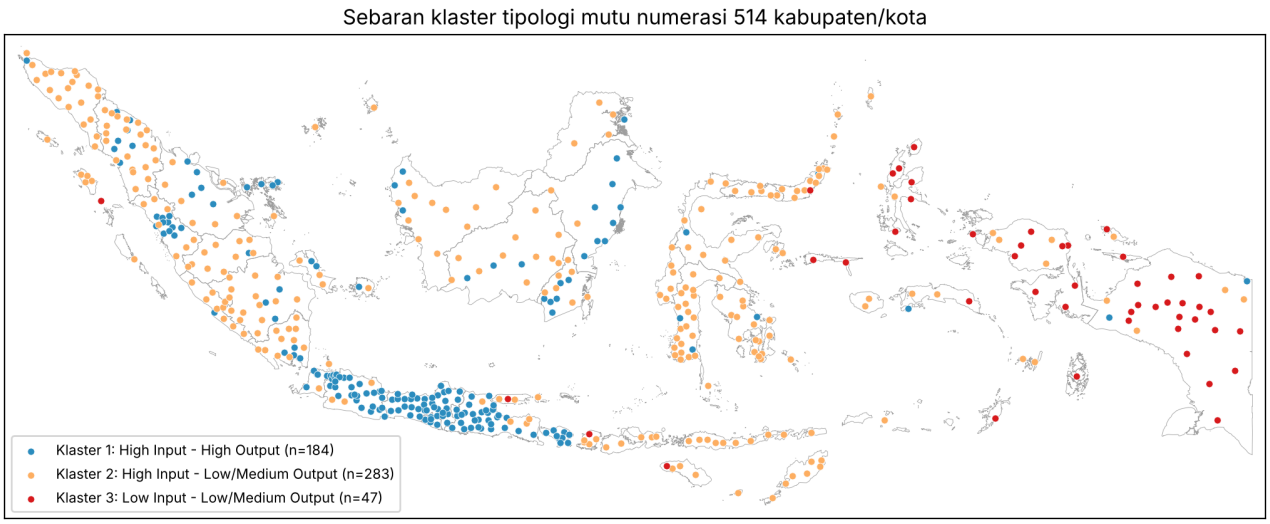
Setiap kab/kota diringkas menjadi 6 dimensi berskala 0–100: Numerasi, Literasi, Kualitas Pembelajaran, Iklim Sekolah, SDM Guru, dan TIK & Sarpras (rata-rata empat jenjang). K-Means dan Agglomerative (Ward) dibandingkan untuk k = 2 sampai 8 dengan dua cara penskalaan, memakai Elbow, Silhouette, dan Davies-Bouldin; HDBSCAN dipakai sebagai pembanding.

Konfigurasi (k = 3)	Silhouette	Davies-Bouldin	Ukuran klaster	Dipakai?
K-Means, StandardScaler	0,385	0,896	283 / 184 / 47	Ya
Agglomerative (Ward), StandardScaler	0,356	0,900	318 / 137 / 59	Tidak: silhouette lebih rendah
K-Means, RobustScaler	0,614	0,674	431 / 59 / 24	Tidak: klaster terkecil < 5%
Agglomerative (Ward), RobustScaler	0,687	0,617	460 / 39 / 15	Tidak: klaster terkecil < 5%

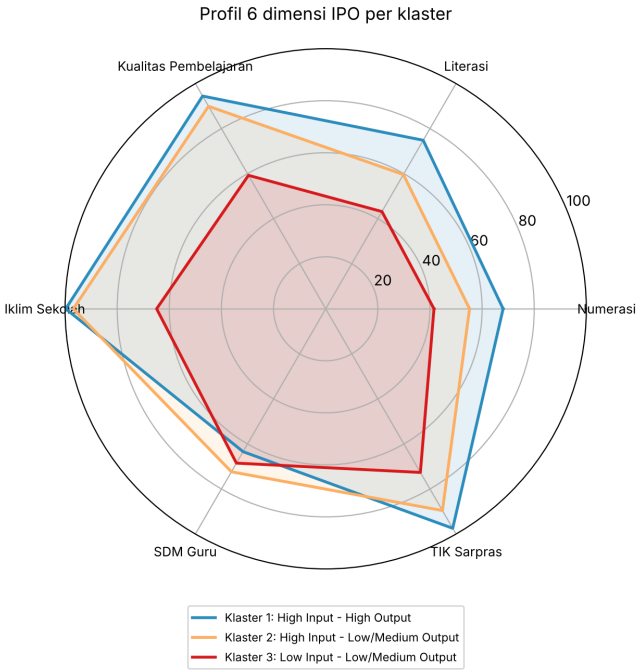
Konfigurasi RobustScaler memberi silhouette lebih tinggi, tetapi hanya memisahkan 15–59 wilayah ekstrem dan menyisakan satu klaster raksasa, sehingga tidak berguna sebagai tipologi kebijakan. Aturan pemilihan (k = 3 sesuai blueprint, tiap klaster minimal 5%, lalu silhouette tertinggi) tertulis di notebook. Silhouette 0,385 tergolong sedang: strukturnya lebih mirip gradasi daripada kelompok yang terpisah tegas.

Klaster	n	Numerasi	Literasi	Kualitas Pembel.	Iklim	SDM Guru	TIK Sarpras
Klaster 1: High Input - High Output	184	68,1	74,8	94,4	99,8	63,4	97,4
Klaster 2: High Input - Low/Medium Output	283	55,2	59,6	89,9	96,8	72,4	89,6
Klaster 3: Low Input - Low/Medium Output	47	41,5	43,2	59,3	64,9	68,5	72,6

- **Klaster 1 (184):** input dan output tinggi, terkonsentrasi di Jawa dan ditambah sebagian Sumatera dan Kalimantan Timur. Benchmark nasional.
- **Klaster 2 (283):** input tinggi tetapi output sedang-rendah. Ini tipe paradoks sarpras dalam blueprint dan jumlahnya paling besar, tersebar di Sumatera, Kalimantan, Sulawesi, dan Nusa Tenggara. Selisih terbesar terhadap Klaster 1 ada di numerasi dan literasi, bukan di fasilitas.
- **Klaster 3 (47):** input dan output rendah, terutama Papua dan Maluku. Kualitas pembelajaran (59) dan iklim sekolah (65) jauh di bawah dua klaster lain. Prioritas afirmasi.



Gambar 1. Sebaran klaster 514 kabupaten/kota.



Gambar 2. Profil 6 dimensi IPO per klaster.

Analisis Transisi MIPA antar Jenjang

Selisih skor numerasi dihitung di kab/kota yang sama. Secara nasional numerasi naik dari SD ke SMP (median +7,0), lalu turun ke SMA (−5,0) dan hampir datar ke SMK (−0,9). Transisi ditandai anomali bila penurunannya di bawah Q1 − 1,5 × IQR, atau bila numerasi SD berlabel Baik/Sedang tetapi jenjang lanjutan berlabel Kurang.

Klaster	Kab/kota	Anomali	Persen
Klaster 1: High Input - High Output	184	32	17,4%
Klaster 2: High Input - Low/Medium Output	283	36	12,7%
Klaster 3: Low Input - Low/Medium Output	47	12	25,5%
Total	514	80	15,6%

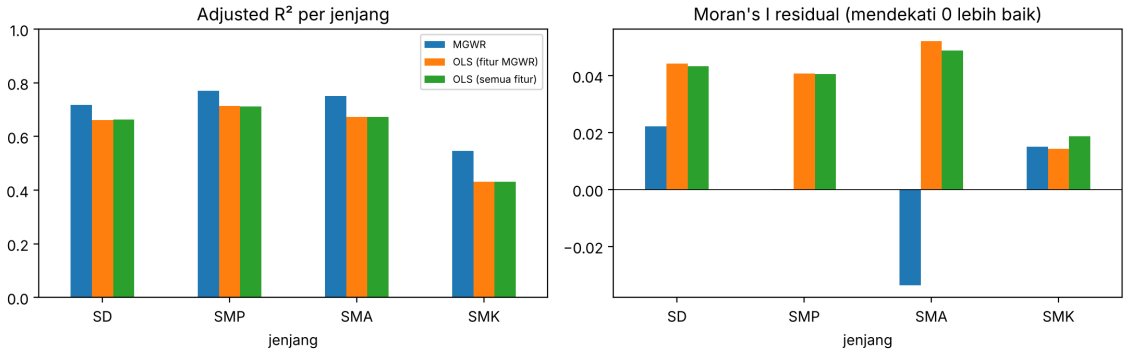
Anomali paling tajam ada di Jawa Tengah dan Jawa Barat (Grobogan, Ciamis, Kota Banjar: turun 24–29 poin dari SD ke SMP). Catatan: skor SD dan SMP berasal dari kalibrasi provinsi dan label, sehingga beberapa kab/kota satu provinsi memiliki nilai kembar; anomali ini lebih tepat dibaca sebagai sinyal untuk dicek, bukan angka pasti.

3. Regresi Spasial: OLS Global vs MGWR

Model dijalankan per jenjang (n = 514 per jenjang) dengan target dan fitur distandarkan, kernel bisquare adaptif, bandwidth dipilih lewat AICc, dan jarak bola. Fitur yang lebih dari 95% barisnya bernilai sama pada suatu jenjang dikeluarkan dari MGWR agar matriks lokal tidak singular. OLS dihitung dua kali (semua fitur dan fitur yang sama dengan MGWR) agar perbandingannya adil.

Jenjang	Model	Adj R^2	AICc	RMSE	MAE	Moran's I residual
SD	OLS (semua fitur)	0,664	923,0	7,74	5,78	0,043
SD	MGWR	0,717	863,7	6,92	5,16	0,022
SMP	OLS (semua fitur)	0,712	844,0	7,57	5,77	0,041
SMP	MGWR	0,769	779,8	6,49	4,85	0,000
SMA	OLS (semua fitur)	0,672	910,2	7,12	5,59	0,049
SMA	MGWR	0,750	841,1	5,86	4,03	-0,034
SMK	OLS (semua fitur)	0,431	1193,0	6,87	4,90	0,019
SMK	MGWR	0,546	1108,7	5,97	3,60	0,015

- MGWR menurunkan AICc 59–84 poin dan menaikkan Adj R^2 0,05–0,12 di semua jenjang. Karena AICc menghukum jumlah parameter, keunggulan ini bukan sekadar efek model yang lebih rumit.
- Residual MGWR hampir tidak berautokorelasi (Moran's I mendekati 0), artinya pola spasial sudah banyak tertangkap.
- Metrik MGWR dihitung in-sample sehingga tidak boleh dibandingkan langsung dengan R^2 uji LightGBM.

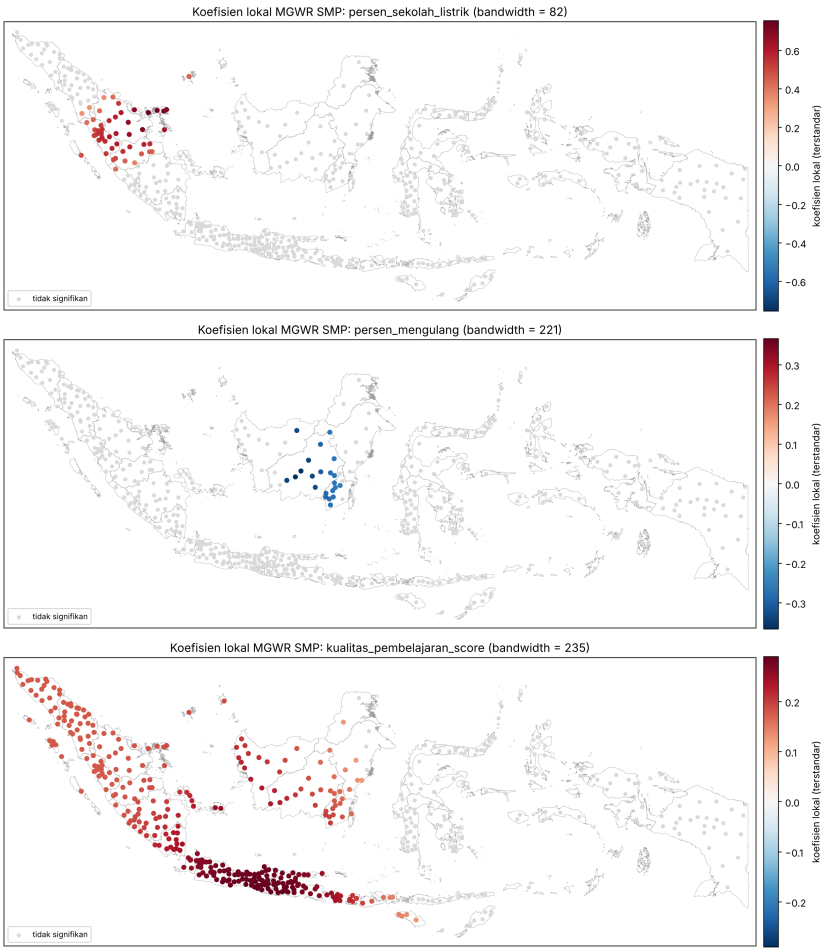


Gambar 3. Adj R^2 dan Moran's I residual per jenjang, OLS vs MGWR.

Bandwidth dan Koefisien Lokal

Bandwidth kecil berarti pengaruh variabel sangat berbeda antar wilayah, sedangkan bandwidth mendekati 514 berarti pengaruhnya hampir seragam. Contoh pada SMP: listrik sekolah (82), indeks pemerataan guru (128), persen mengulang (221), kualitas pembelajaran (235). Kualitas pembelajaran signifikan di 67% lokasi SMP dan koefisiennya paling kuat di Jawa. Listrik sekolah hanya signifikan di sebagian Sumatera, dan persen mengulang hanya di Kalimantan Tengah dan sekitarnya.

Pada SMA, faktor yang signifikan hampir hanya literasi; di 485 dari 514 kab/kota tidak ada tuas kebijakan yang signifikan, sehingga faktor dominan MGWR untuk SMA tidak bisa dipakai sebagai dasar diagnosis.



Gambar 4. Koefisien lokal MGWR jenjang SMP untuk tiga variabel dengan bandwidth terkecil (abu-abu = tidak signifikan).

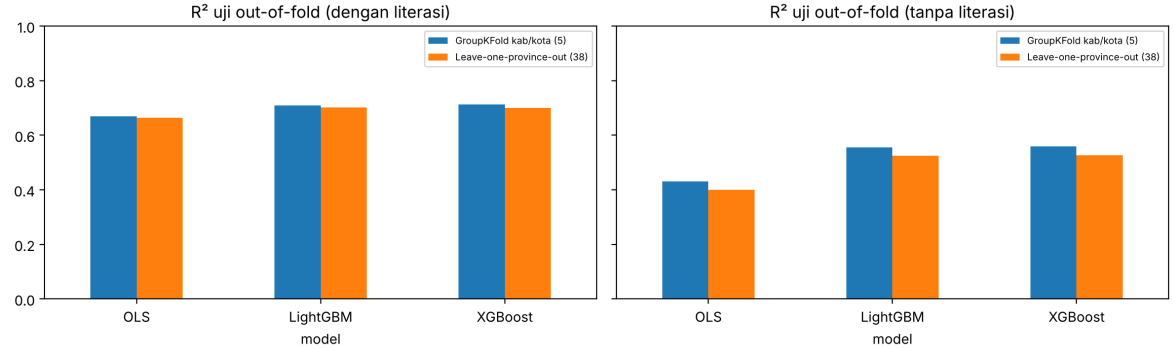
4. Model Non-Linear: LightGBM, XGBoost, dan SHAP

Model dilatih pada gabungan 4 jenjang (2.056 baris, jenjang sebagai dummy) dan dievaluasi out-of-fold dengan dua skema: GroupKFold per kab/kota (5 fold) dan leave-one-province-out (38 fold), yaitu uji pada provinsi yang tidak pernah dilihat model. Tingkat regularisasi LightGBM dipilih hanya dari skema pertama supaya skor leave-one-province-out tidak ikut dipakai untuk memilih model.

Fitur	Validasi	Model	R^2 latih	R^2 uji	RMSE uji	MAE uji
Dengan literasi	GroupKFold kab/kota	OLS	0,678	0,670	7,64	5,76
Dengan literasi	GroupKFold kab/kota	LightGBM	0,777	0,709	7,18	5,01
Dengan literasi	GroupKFold kab/kota	XGBoost	0,782	0,713	7,13	4,95
Dengan literasi	Leave-province-out	OLS	0,677	0,664	7,71	5,84
Dengan literasi	Leave-province-out	LightGBM	0,773	0,702	7,27	5,21
Dengan literasi	Leave-province-out	XGBoost	0,775	0,700	7,29	5,22
Tanpa literasi	GroupKFold kab/kota	OLS	0,452	0,431	10,03	7,95
Tanpa literasi	GroupKFold kab/kota	LightGBM	0,649	0,555	8,87	6,53
Tanpa literasi	GroupKFold kab/kota	XGBoost	0,662	0,559	8,84	6,42
Tanpa literasi	Leave-province-out	OLS	0,451	0,400	10,31	8,15
Tanpa literasi	Leave-province-out	LightGBM	0,643	0,524	9,18	6,76
Tanpa literasi	Leave-province-out	XGBoost	0,652	0,526	9,16	6,70

- Pada leave-one-province-out, LightGBM 0,70 dan XGBoost 0,70 dibanding OLS 0,66. Selisih R^2 latih dan uji sekitar 0,07, jadi tidak overfit.

- Tanpa literasi, semua model turun: LightGBM 0,52, XGBoost 0,53, OLS 0,40. Keunggulan model non-linear terhadap OLS lebih besar di spesifikasi ini (+0,12).
- Error rata-rata sekitar 5,2 poin (MAE) pada skala skor 23–98.

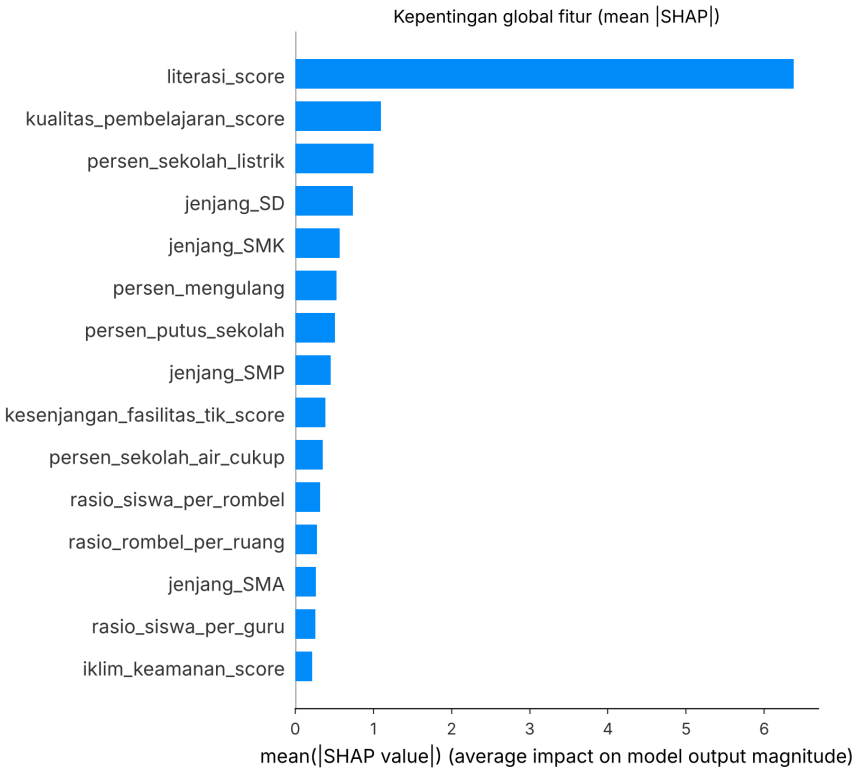


Gambar 5. R² uji out-of-fold, dengan dan tanpa literasi.

Kepentingan Fitur (TreeSHAP)

Fitur	Kelompok	mean |SHAP|
literasi_score	X4 Kerentanan & Efisiensi	6,38
kualitas_pembelajaran_score	X3 Iklim & Pedagogik	1,10
persen_sekolah_listrik	X2 Sarpras & TIK	1,00
persen_mengulang	X4 Kerentanan & Efisiensi	0,53
persen_putus_sekolah	X4 Kerentanan & Efisiensi	0,51
kesenjangan_fasilitas_tik_score	X2 Sarpras & TIK	0,39
persen_sekolah_air_cukup	X2 Sarpras & TIK	0,35
rasio_siswa_per_rombel	X2 Sarpras & TIK	0,32

Literasi dominan (6,4), sekitar 6 kali fitur berikutnya. Di luar literasi, kontributor terbesar adalah kualitas pembelajaran (D.1, 1,10), listrik sekolah (1,00), persen mengulang (0,53), dan putus sekolah (0,51). Per kab/kota, tiga fitur dengan kontribusi paling negatif disimpan sebagai "top 3 akar masalah" (file top3_akar_masalah.csv) untuk modul diagnosis di web.



Gambar 6. Kepentingan global fitur (mean |SHAP|).

5. Simulasi Intervensi Kebijakan

Model LightGBM final dipakai sebagai mesin inferensi: ΔY = Ŷ(simulasi) − Ŷ(aktual), dengan perubahan dibatasi maksimal ±25% dari nilai awal dan tetap dalam rentang data. Skenario blueprint: akses internet +15 poin, rasio siswa per rombel −5, kualitas pembelajaran +10 poin.

Klaster	SD	SMP	SMA	SMK
Klaster 1: High Input - High Output	0,42	-0,80	-0,42	1,24
Klaster 2: High Input - Low/Medium Output	0,35	0,39	0,05	0,69
Klaster 3: Low Input - Low/Medium Output	0,92	0,36	-0,05	0,52

Rata-rata ΔY nasional 0,28 poin (median 0,14); 60,1% baris mengalami kenaikan. Efek per tuas pada batas +25% (arah perbaikan) paling besar untuk kualitas pembelajaran (+0,80), listrik sekolah (+0,75), dan air bersih (+0,51). Tiga tuas berefek negatif: rasio siswa per rombel (−0,29), pemerataan guru (−0,22), dan rasio siswa per guru (−0,14).

Cara membaca simulasi. Efek yang kecil dan sebagian berlawanan arah menunjukkan bahwa model hanya mempelajari pola asosiasi dari data satu tahun, bukan hubungan sebab-akibat. Contohnya rombel besar lebih banyak di wilayah perkotaan yang capaiannya tinggi. Hasil simulasi sebaiknya dibaca bersama koefisien MGWR dan disajikan sebagai estimasi, bukan prediksi dampak pasti.

6. Keterbatasan dan Langkah Berikutnya

Keterbatasan untuk ditulis di bagian Batasan Masalah makalah:

- Data satu tahun (2025), jadi tidak ada analisis tren atau forecasting dan semua hubungan bersifat asosiasi.
- *numerasi_score* dan *literasi_score* adalah estimasi kalibrasi dari SKM provinsi dan label Rapor. Sebagian variasi antar kab/kota satu provinsi berasal dari label, bukan pengukuran langsung.
- Sebagian kolom Dapodik (rasio guru, putus sekolah, internet, listrik, air) belum bisa diverifikasi dari sumber aslinya oleh penyusun notebook; sumbernya perlu dikonfirmasi tim sebelum dicantumkan di makalah.
- Baris dengan label "Tidak Tersedia" (10 baris) dan skor ordinal hasil imputasi (13 baris) tertandai, tetapi tetap ikut dilatih pada model non-linear.
- Kolom *kesenjangan_fasilitas_tik_score* berarah terbalik (tinggi = kesenjangan besar) dibanding skor lain; interpretasi SHAP dan simulator perlu memperhatikan ini.

Langkah berikutnya yang disarankan:

- Menambahkan uji out-of-sample untuk MGWR agar perbandingan dengan LightGBM adil.
- Membangun web NUSA-MIPA dari file di folder outputs (peta klaster, radar, diagnosis SHAP dan MGWR, simulator).
- Menulis makalah mengikuti format tahun lalu setelah proyek selesai, dengan hasil dilaporkan untuk dua spesifikasi (dengan dan tanpa literasi).